

PHIẾU ĐỀ XUẤT ĐỒ ÁN

Môn Khai phá Dữ liệu

1. Bộ dữ liệu đã chọn và lý do chọn

Bộ dữ liệu: US Accidents, kế thừa 80.000 sự cố (64.000 train / 16.000 test), chia ngẫu nhiên 80/20 cố định theo ID, stratify theo bốn lớp Severity. Tập trung tại California (59.903 sự cố) và Texas (20.097 sự cố). Biến mục tiêu (Severity) được gộp nhị phân: Severity 1–2 (ảnh hưởng giao thông thấp/vừa) và Severity 3–4 (ảnh hưởng giao thông cao, chiếm 17,68% trong tập test).

Lý do chọn:

- Đa dạng thuộc tính: kết hợp đủ đặc trưng thời gian (Start-Time), hạ tầng (Junction, Crossing) và thời tiết (Temperature, Visibility) — phù hợp cho cả luật kết hợp lẫn phân lớp.
- Thách thức mất cân bằng lớp: tỷ lệ Severity 3–4 chỉ 17,68%, phản ánh bài toán mất cân bằng thực tế, đòi hỏi thuật toán nâng cao như Balanced Random Forest.
- Phản ánh rủi ro thiên lệch nguồn: tỷ lệ Severity 3–4 chênh lệch lớn giữa các nguồn ghi nhận (Source1: 4,36%, Source2: 35,36%), tạo bối cảnh lý tưởng để kiểm chứng độ bền của mô hình.

2. Câu hỏi dẫn dắt

Đồ án tập trung giải quyết ba câu hỏi nghiên cứu sau, cùng ý nghĩa thực tế và kỹ thuật dự kiến sử dụng để trả lời:

Câu hỏi	Nội dung câu hỏi dẫn dắt	Giúp ích cho ai / quyết định gì	Kỹ thuật dự kiến kết hợp
Q1	Tổ hợp điều kiện thời gian, thời tiết và hạ tầng nào đi cùng tỷ lệ sự cố ảnh hưởng giao thông cao (Severity 3–4) lớn hơn rõ rệt so với mức nền?	Đội điều phối/phân tích giao thông tại CA/TX — quyết định gắn cờ ưu tiên rà soát khi sự cố mới thỏa các tổ hợp điều kiện này.	Luật kết hợp (Apriori/FP-Growth) khai phá trên tập train; đánh giá Support, Confidence, Lift trên tập test; bootstrap CI 95% và kiểm định phân tầng theo Source/State để xác nhận độ bền.
Q2	Mô hình phân lớp nhận diện nhóm sự cố Severity 3–4 đến đâu, và khối lượng bỏ sót (False Negatives) cũng như cảnh báo nhầm (False Positives) thực tế là bao nhiêu trên dữ liệu ngoại tuyến?	Đội vận hành mô hình/người duyệt cảnh báo — quyết định có nên đưa mô hình vào hỗ trợ cảnh báo sớm, và nên ưu tiên xử lý nhóm điều kiện nào để giảm bỏ sót.	Phân lớp baseline (Decision Tree/Random Forest) và phân tích ma trận nhầm lẫn theo lát cắt antecedent; thử nghiệm kỹ thuật nâng cao Balanced Random Forest (imbalanced-learn) để giảm bỏ sót ở lớp thiểu số.
Q3	Luật điều kiện và mô hình phân lớp bổ sung, xác nhận hay mâu thuẫn/cảnh báo giới hạn của nhau ra	Nhóm phân tích dữ liệu/người chốt insight — quyết định có nên tin dùng một tổ hợp điều kiện (rule)	Nối kết quả luật kết hợp và điểm rủi ro (risk score) của mô hình phân lớp theo ID sự cố trên cùng tập test; đối

Câu hỏi	Nội dung câu hỏi dẫn dắt	Giúp ích cho ai / quyết định gì	Kỹ thuật dự kiến kết hợp
	sao khi kiểm tra trên cùng tập test và phân tầng theo nguồn ghi nhận (Source) hoặc địa bàn (CA, TX)?	để đưa vào vận hành hay phải loại bỏ vì không ổn định giữa các nguồn dữ liệu.	chiều chiều tăng/giảm và kiểm định phân tầng theo Source/State.

3. Ghi chú

Ba câu hỏi được thiết kế để cùng soi trên một tập test duy nhất (16.000 sự cố, nối theo ID), nhằm bảo đảm phân tổng hợp liên kỹ thuật (Mục 4.1 của Hướng dẫn đồ án) có cơ sở đối chiếu trực tiếp giữa luật kết hợp và mô hình phân lớp, thay vì trình bày rời rạc từng kỹ thuật.